

1. Présentation du dataset

Le dataset utilisé est le dataset California Housing fourni par scikit-learn.

Il contient des informations socio-économiques et géographiques sur des districts de Californie, avec pour objectif de prédire la variable cible MedHouseVal qui représente la valeur médiane des logements.

Le dataset contient :

- 20640 observations
- 9 variables numériques

Les variables sont les suivantes :

- **MedInc** : Revenu médian (en 10K \$).
- **HouseAge** : Âge médian des maisons.
- **AveRooms** : Nombre moyen de pièces par logement.
- **AveBedrms** : Nombre moyen de chambres par logement.
- **Population** : Taille de la population dans le secteur.
- **AveOccup** : Occupation moyenne par maison.
- **Latitude** : Latitude.
- **Longitude** : Longitude.

Aucune variable ne contient de valeurs manquantes. Et donc le dataset est propre au niveau des données manquantes.

2. Analyse statistique descriptive

	MedInc	HouseAge	AveRooms	AveBedrms	Population	AveOccup	Latitude	Longitude	MedHouseVal
count	20640.00000	20640.00000	20640.00000	20640.00000	20640.00000	20640.00000	20640.00000	20640.00000	20640.00000
mean	3.870671	28.639486	5.429000	1.096675	1425.476744	3.070655	35.631861	-119.569704	2.068558
std	1.899822	12.585558	2.474173	0.473911	1132.462122	10.386050	2.135952	2.003532	1.153956
min	0.499900	1.000000	0.846154	0.333333	3.000000	0.692308	32.540000	-124.350000	0.149990
25%	2.563400	18.000000	4.440716	1.006079	787.000000	2.429741	33.930000	-121.800000	1.196000

Analyse Exploratoire des Données

50 %	3.534800	29.000000	5.229129	1.048780	1166.000000	2.818116	34.260000	-118.490000	1.797000
75 %	4.743250	37.000000	6.052381	1.099526	1725.000000	3.282261	37.710000	-118.010000	2.647250
max	15.000100	52.000000	141.909091	34.066667	35682.000000	1243.333333	41.950000	-114.310000	5.000010

Certaines variables présentent des valeurs maximales extrêmement élevées par rapport à leur médiane.

Notamment :

Variable	Médiane	Maximum
AveRooms	5.23	141.91
AveBedrms	1.04	34.06
Population	1166	35682
AveOccup	2.81	1243.33

Ces écarts importants indiquent la présence probable de valeurs aberrantes et de distributions asymétriques.

La variable cible :

MedHouseVal


présente :

- une moyenne de 2.07,
- une médiane de 1.79,
- une valeur maximale de 5.

3. Analyse des distributions

Les histogrammes des variables montrent plusieurs comportements intéressants.

Analyse Exploratoire des Données




Variables asymétriques:

Les variables :

- Population
- AveOccup
- AveRooms
- AveBedrms

présentent une forte asymétrie positive.

4. Analyse des boxplots (détection des outliers)



Les boxplots mettent en évidence la présence de nombreuses valeurs aberrantes.

Les variables les plus affectées sont :

- AveRooms
- AveBedrms
- Population
- AveOccup

Ils montrent que de nombreuses observations situées au-delà des moustaches, et que des valeurs extrêmement éloignées du cœur de la distribution.

Ces outliers peuvent correspondre :

- à des districts atypiques,
- à des densités de population particulières,
- ou à des observations rares mais réelles.

Plusieurs stratégies pourraient être envisagées :

- suppression des outliers,
- clipping,
- transformation logarithmique,
- utilisation de modèles robustes aux valeurs extrêmes.


5. Gestion des valeurs aberrantes:

Compte tenu de la présence de nombreuses valeurs aberrantes dans le dataset, une stratégie de preprocessing adaptée sera mise en place en fonction des modèles utilisés.

Dans un premier pipeline, nous appliquerons une transformation logarithmique ainsi qu'un RobustScaler afin de réduire l'impact des outliers et des distributions fortement asymétriques. Cette approche est particulièrement pertinente pour la régression linéaire, ce type de modèle étant sensible aux valeurs extrêmes et aux différences d'échelle entre les variables.

Une seconde pipeline sera ensuite construite à partir des données brutes, sans preprocessing important, afin d'entraîner des modèles plus avancés et naturellement plus robustes aux valeurs aberrantes, tels que Random Forest et Gradient Boosting. Cette démarche permettra de comparer l'impact du preprocessing sur les performances des différents modèles.

6. Analyse des corrélations



Corrélation avec la variable cible

La variable la plus fortement corrélée avec **MedHouseVal** est :

MedInc : corrélation ≈ 0.69

Cette corrélation positive relativement élevée indique que le revenu médian des habitants constitue un facteur important dans l'explication du prix des logements.

Les autres variables présentent des corrélations plus faibles avec la cible :

Variable	Corrélation avec MedHouseVal
AveRooms	0.15
HouseAge	0.11
Latitude	-0.14
Longitude	-0.046
Population	-0.025
AveOccup	-0.024

Ces résultats suggèrent que les variables géographiques et socio-économiques influencent davantage le prix des logements que les simples caractéristiques de densité de population.

Corrélations entre variables explicatives

Une très forte corrélation positive est observée entre :

AveRooms et AveBedrms : 0.85

Cela est cohérent puisque le nombre moyen de chambres est naturellement lié au nombre moyen de pièces.

Cette forte corrélation peut indiquer une certaine redondance d'information entre ces deux variables.

Corrélations géographiques

Une très forte corrélation négative est observée entre :

Latitude et Longitude : -0.92

Cela traduit la structure géographique particulière du dataset et la répartition des districts en Californie.